

Estimación, diagnóstico y pronóstico de los modelos

Javier López

Universidad los Libertadores

Abril, 2020

Índice

- 1 Estimación
- 2 Diagnóstico
- 3 Pronóstico

Estimación del Modelo

El objetivo es estimar los parámetros del modelo *ARIMA* a partir de valores observados Y_1, Y_2, \dots, Y_n

Asumimos que el modelo ha sido especificado con valores de p, d, q . Sabemos que d lo tenemos por diferenciación, luego estimamos los parámetros de un *ARMA*(p, q).

Método de Momentos

Autoregresivo:

- **AR(1):** Tenemos que $\rho_1 = \phi$, luego igualando ρ_1 a γ_1 por el método de momentos, tenemos que $\hat{\phi} = \gamma_1$
- **AR(2):** $\rho_1 = \phi_1 + \rho_1\phi_2$ y $\rho_2 = \rho_1\phi_1 + \phi_2$,
luego por momentos tenemos que $\rho_1 = \gamma_1$ y $\rho_2 = \gamma_2$, así

$$\hat{\phi}_1 = \frac{\gamma_1(1 - \gamma_2)}{(1 - \gamma_1^2)} \text{ y } \hat{\phi}_2 = \frac{\gamma_2 - \gamma_1^2}{1 - \gamma_1^2}$$
- **AR(p):** Tenemos por la ecuaciones de Yule-Walker estimadas:

$$\phi_1 + \gamma_1\phi_2 + \gamma_2\phi_3 + \dots + \gamma_{p-1}\phi_p = \gamma_1$$

$$\gamma_1\phi_1 + \phi_2 + \gamma_1\phi_3 + \dots + \gamma_{p-2}\phi_p = \gamma_2$$

$$\vdots$$

$$\gamma_{p-1}\phi_1 + \gamma_{p-2}\phi_2 + \gamma_{p-3}\phi_3 + \dots + \phi_p = \gamma_p$$

Método de Momentos

Media Móvil:

- **MA(1):** Tenemos que $\rho_1 = \frac{-\theta}{1 + \theta^2}$, igualando ρ_1 a γ_1 , tenemos dos raíces reales dadas por:

$$\hat{\theta} = \frac{-1}{2\gamma_1} \pm \sqrt{\frac{1}{4\gamma_1^2} - 1} = \frac{-1 \pm \sqrt{1 - 4\gamma_1^2}}{2\gamma_1}$$

Con $|\gamma_1| < 0,5$.

- Para Medias Móviles de orden más alto puede ser complicado ya que se pueden producir estimaciones pobres dadas por las ecuaciones no lineales en θ

Método de Momentos

Modelos Mixtos:

- **ARMA(1,1):** Tenemos que $\rho_k = \frac{(1 - \theta\phi)(\phi - \theta)}{1 - 2\theta\phi + \theta^2} \phi^{k-1}$, para $k \geq 1$

Note que $\frac{\rho_2}{\rho_1} = \phi$, luego $\hat{\phi} = \frac{\gamma_2}{\gamma_1}$ así,

$$\gamma_1 = \frac{(1 - \theta\hat{\phi})(\hat{\phi} - \theta)}{1 - 2\theta\hat{\phi} + \theta^2}$$

Para encontrar $\hat{\theta}$ resolvemos la ecuación cuadrática.

Método de Momentos - Estimación de Varianza

- Para todos los casos necesitamos estimar σ_e^2 , inicialmente $\gamma_0 = \text{Var}(Y_t)$ que es la varianza muestral, con:

$$s^2 = \frac{1}{n-1} \sum_{t=1}^n (Y_t - \bar{Y})^2$$

- Para **AR(p)**: $\hat{\sigma}_e^2 = (1 - \hat{\phi}_1\gamma_1 - \hat{\phi}_2\gamma_2 - \dots - \hat{\phi}_p\gamma_p)s^2$
- Para **MA(q)**: $\hat{\sigma}_e^2 = \frac{s^2}{1 + \hat{\theta}_1^2 + \hat{\theta}_2^2 + \dots + \hat{\theta}_q^2}$
- Para **ARMA(1,1)**: $\hat{\sigma}_e^2 = \frac{1 - \hat{\phi}^2}{1 - 2\hat{\theta}\hat{\phi} + \hat{\theta}^2}$

Esquema de simulación y estimación por Momentos

Modelo	Parámetros	Estimación	n
MA(1)	-0.9	-0.86	120
MA(1)	0.9	0.78	120
MA(1)	-0.9	-0.81	60
MA(1)	0.9	0.83	60
MA(1)	0.5	0.6	60
AR(1)	0.9	0.81	60
AR(1)	0.4	0.42	60
AR(2)	(1.5, -0.75)	(1.21, -0.52)	120

Ver código en R

Estimación de Mínimos Cuadrados

Autoregresivo:

- **AR(1):** $Y_t - \mu = \phi(Y_{t-1} - \mu) + e_t$,
luego $e_t = (Y_t - \mu) - \phi(Y_{t-1} - \mu)$

Así tenemos la suma de cuadrados condicionales:

$$S_c(\phi, \mu) = \sum_{t=2}^n [(Y_t - \mu) - \phi(Y_{t-1} - \mu)]^2$$

$$\frac{\delta S_c(\phi, \mu)}{\delta \mu} = 0 \Rightarrow \hat{\mu} \approx \frac{\bar{Y} - \phi \bar{Y}}{1 - \phi} = \bar{Y}$$

$$\frac{\delta S_c(\phi, \mu)}{\delta \phi} = 0 \Rightarrow \hat{\phi} = \frac{\sum_{t=2}^n (Y_t - \bar{Y})(Y_{t-1} - \bar{Y})}{\sum_{t=2}^n (Y_{t-1} - \bar{Y})^2}$$

- **AR(2):** $\hat{\mu} = \bar{Y}$, y por las ecuaciones de Yule-Walker estimadas

$$\gamma_1 = \hat{\phi}_1 + \gamma_1 \hat{\phi}_2$$

$$\gamma_2 = \gamma_1 \hat{\phi}_1 + \hat{\phi}_2$$

Así sucesivamente para el orden n

Estimación Mínimos Cuadrados

Media Movil:

- **MA(1):** $Y_t = e_t - \theta e_{t-1}$

Podemos escribirlo como un $AR(\infty)$,

luego: $Y_t = -\theta Y_{t-1} - \theta^2 Y_{t-2} - \dots + e_t$

$$S_c(\theta) = \sum (e_t)^2 = \sum [Y_t + \theta Y_{t-1} + \theta^2 Y_{t-2} + \dots]^2$$

Esto se resume a un problema no linear, luego se resolverá con técnicas de optimización numérica, utilizando métodos de Gauss-Newton o Nelder-Mead

Estimación Máxima Verosimilitud

Ventaja: Se utiliza toda la información de los datos, inclusive el primer y segundo momento.

Desventaja: Trabaja con una función de densidad de probabilidad.

- **AR(1):** Asumimos $e_t \sim^{iid} N(0, \sigma_e^2)$, luego la *f.d.p* marginal es $Y_t \sim N(\mu, \frac{\sigma_e^2}{(1-\phi^2)})$, así tenemos que:

$$L(\phi, \mu \sigma_e^2) = (2\pi \sigma_e^2)^{-\frac{n}{2}} (1 - \phi^2)^{\frac{1}{2}} \exp\left[-\frac{1}{2\sigma_e^2} S(\phi, \mu)\right]$$

con $S(\phi, \mu) = \sum_{t=2}^n [(Y_t - \mu) - \phi(Y_{t-1} - \mu)]^2 + (1 - \phi^2)(Y_1 - \mu)^2$
 Luego maximizamos el logaritmo de la función de cuadrados no condicionales para encontrar la estimación de los parámetros.

Propiedades de las estimaciones



	Parámetros	Momentos	MCO	MV	n
AR(1)	0.9	0.831	0.857	0.892	60
	0.4	0.470	0.473	0.465	60

	Parámetros	Momentos	MCO	MV	n
AR(2)	$\phi_1 = 1,5$	1.472	1.513	1.506	120
	$\phi_2 = -0,75$	-0.767	-0.805	-0.796	120

	Parámetros	Momentos	MCO	MV	n
ARMA(1,1)	$\phi_1 = 0,6$	0.637	0.558	0.564	100
	$\phi_2 = -0,3$	-0.206	-0.366	-0.355	100


Diagnóstico del Modelo - Ejemplo practico

Serie de tiempo de abundancia de liebres en Canada (1905-1935)




Especificación del Modelo - Serie de Tiempo Liebres



ACF Liebres^{1/2}



PACF Liebres^{1/2}



Ajuste del Modelo - Serie de Tiempo Liebres



Diagnóstico del Modelo - ACF de los residuos


Para analizar la independencia del ruido del modelo, consideramos el ACF de los residuos. Los residuos están normalmente distribuidos con media cero y varianza $\frac{1}{n}$, luego los $\hat{\gamma}_k, \hat{\gamma}_j$ son aproximadamente no correlacionados.

Utilizamos el Test de Ljung-Box para contrastar la hipótesis de no correlación.


$$Q = n(n+2) \left(\frac{\hat{\gamma}_1^2}{n-1} + \frac{\hat{\gamma}_2^2}{n-2} + \dots + \frac{\hat{\gamma}_k^2}{n-k} \right)$$

Diagnóstico del Modelo - Serie de Tiempo Liebres

ACF Residuales AR(2)




ACF Residuales AR(3)




Diagnóstico del Modelo - Serie de Tiempo Liebres


Q-Q Plot AR(2)





Q-Q Plot AR(3)



Diagnóstico del Modelo - Serie de Tiempo Liebres



Pronóstico del Modelo - Serie de Tiempo Liebres



Pronóstico del Modelo

- **AR(1):**

$$Y_t - \mu = \phi(Y_{t-1} - \mu) + e_t$$

$$Y_{t+1} - \mu = \phi(Y_t - \mu) + e_{t+1}$$

$$\hat{Y}_t(1) - \mu = \phi(E(Y_t | Y_1, Y_2, \dots, Y_t) - \mu) + E(e_{t+1} | Y_1, Y_2, \dots, Y_t)$$

$$\hat{Y}_t(1) = \mu + \phi(Y_t - \mu)$$

Para el tiempo w tenemos:

$$\hat{Y}_t(w) = \mu + \phi[\hat{Y}_t(w-1) - \mu]$$

para $w > 1$

De manera recursiva podemos ver:

$$\hat{Y}_t(w) = \mu + \phi^w(Y_t - \mu)$$

Pronóstico del Modelo

- **MA(1):**

$$Y_t = \mu + e_t - \theta e_{t-1}$$

$$\hat{Y}_t(1) = \mu - \theta E(e_t | Y_1, Y_2, \dots, Y_t)$$

$$\hat{Y}_t(1) = \mu - \theta e_t$$

En general

$$\hat{Y}_t(w) = \mu + E(e_{t+w} | Y_1, Y_2, \dots, Y_t) - \theta E(e_{t+w-1} | Y_1, Y_2, \dots, Y_t)$$

para $w > 1$, e_{t+w} y e_{t+w-1} son independientes de Y_1, Y_2, \dots, Y_t , luego

$$\hat{Y}_t(w) = \mu$$

para $w > 1$

Pronóstico del Modelo

Predicción de límites de confianza:

Si el componente estadístico es normalmente distribuido, entonces el error de pronóstico dado por:

$$e_t(w) = Y_{t+w} - \hat{Y}_t(w)$$

también está normalmente distribuido, luego para un nivel de confianza de $1 - \alpha$ tenemos que:

$$P \left[-z_{1-\frac{\alpha}{2}} < \frac{Y_{t+w} - \hat{Y}_t(w)}{\sqrt{\text{Var}(e_t(w))}} < z_{1-\frac{\alpha}{2}} \right] = 1 - \alpha$$

luego un intervalo de confianza de $(1 - \alpha)100\%$ ara Y_{t+w} está dado por:

$$\hat{Y}_t(w) \pm z_{1-\frac{\alpha}{2}} \sqrt{\text{Var}(e_t(w))}$$

THANK YOU

GRACIAS

ARIGATO

SHUKURIA

JUSPAXAR

DANKSCHEEN

TASHAKKUR ATU

YAQHANYELAY

BIYAN

SHUKRIA

TINGKI

SUKSAMA

EKMET

MEHRBANI

PALDIES

BOLZIN

MERCİ

GOZAIMASHITA

EFCHARISTO

KOMAPSUNIDA

MAAKE

GAEJTHO

MERASTANHY

TAVTAPUCH

MEDAWAGSE

BAUKA

SPASSIBO

SNACHALHUYA

NURUN

CHALTU

HABESJA

HAYEKA

HUI

YOSPAGARTAN

SHANYABAD

JANBIA

ATTO

SHIRI

SPASIBO

DENKADJA

HOMACHALHYA

UNALCHESEH

HATIR

GUL

BROJU

SIKOMO

MAKETAI

MIRHACHAR